# Um Índice de Credibilidade do Banco Central Baseado em Modelos de Linguagem

Metodologia e resultados do índice v1.1 com o corpus ampliado

Versão de 22 de outubro de 2026, com o V-min completo

---

**Estado desta versão.** Todos os resultados usam o corpus final (11 veículos, 2011–2026), o pré-filtro retreinado, as notas completas do Sabiá e do Gemini e o V-min de todas as notícias com sinal. Em relação à versão anterior (mesmo dia), muda só a banda de vazamento (Seção 8.3): séries, robustez, validação e eventos são idênticos. Os critérios de aprovação foram registrados antes de rodar (contexto do projeto, seções 4.2.17 e 4.2.20).

## 1 Pergunta e conceito

A credibilidade do banco central é o peso de ancoragem $C_t \in [0, 1]$ que os agentes atribuem à meta ao formar expectativas, contra $(1 - C_t)$ atribuído à inflação passada (Bomfim e Rudebusch, 2000):

$$\widetilde{E}_t[\pi_{t+1}] = C_t\, \pi_t^* + (1 - C_t)\, \pi_{t-1}. \tag{1}$$

Ela é latente. As medidas usuais ou derivam a credibilidade das próprias expectativas, o que torna circular qualquer validação, ou são índices institucionais lentos. Este projeto mede a *credibilidade percebida*: o que a imprensa econômica escreve sobre o Banco Central do Brasil (BCB), lido por um modelo de linguagem (LLM) com um instrumento fixo. A pergunta é:

> *Um índice de credibilidade extraído por LLM da percepção de terceiros sobre o BCB (i) acompanha as medidas de credibilidade implícitas nas expectativas e nos preços, (ii) contém informação além da inflação corrente e (iii) antecipa a ancoragem das expectativas, além do que elas já contêm?*

O índice é extraído da **credibilidade-resposta** (o que a audiência acredita), e não do **esforço de sinalização** do BCB. Por isso o corpus é texto *sobre* o BCB escrito por terceiros, e declarações do BCB reproduzidas numa matéria pesam pelo enquadramento que o veículo lhes dá.

## 2 Corpus

**Veículos e período.** Matérias de janeiro de 2011 a agosto de 2026 em 11 veículos (Figura 1). Os cinco do corpus original (Valor, O Globo, InfoMoney, Money Times, Poder360) foram ampliados com Exame, G1, CartaCapital, Bloomberg Línea, Agência Brasil e Folha. O corpus final tem 110.279 notícias; 10% delas, separadas pelo *hash* do identificador, ficam em quarentena fora da produção (Seção 8.1).

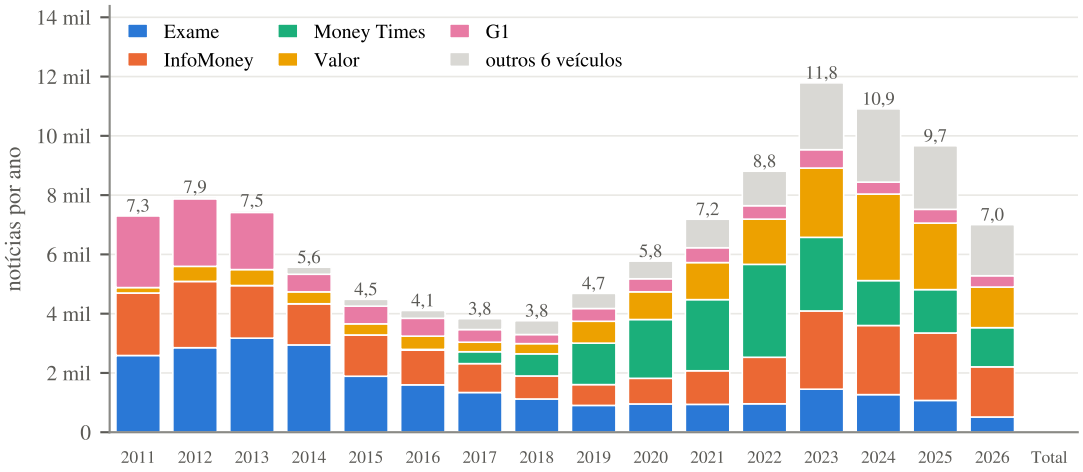
**Coleta.** Termos específicos de política monetária (*Copom*, *Selic*, *ata do Copom*, *política monetária*, *meta de inflação*, *Relatório de Inflação*, *Banco Central*), com um filtro temático local que exige um deles no título, na linha fina ou no primeiro parágrafo. Cada veículo usa o canal que o próprio site oferece:

- busca da Globo (Valor, O Globo, G1; no G1, um plano fixo de 65 consultas, porque a busca não ordena por data);
- API REST do WordPress, por ano (InfoMoney, Money Times, Poder360, Exame, CartaCapital); a paginação para no total informado pelo próprio site;
- sitemaps diários (Bloomberg Línea, desde julho de 2021) e listagem da seção Economia (Agência Brasil, 10 s entre requisições como pede o site), com pré-filtro pelas palavras do endereço;
- a Folha foi coletada pela equipe com coletor próprio, sob autorização da FEA, e cobre 2018 em diante.

Valor e O Globo são coletados sob acesso concedido à equipe. A listagem da Agência Brasil só alcança janeiro de 2014; a seção Política ficou de fora.

**Unidade e deduplicação.** Cada item é título, linha fina e primeiro parágrafo. A mesma URL conta uma vez; a mesma matéria em duas URLs, no mesmo veículo e dia, também. Matérias de agência replicadas em vários veículos formam um *cluster* e contam uma vez por mês. A data é a hora local de Brasília.

**Corpus com 11 veículos: 110.279 notícias de 2011 a 2026**




| | 2011 | 2012 | 2013 | 2014 | 2015 | 2016 | 2017 | 2018 | 2019 | 2020 | 2021 | 2022 | 2023 | 2024 | 2025 | 2026 | Total |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Exame | 2.589 | 2.852 | 3.174 | 2.946 | 1.889 | 1.599 | 1.340 | 1.122 | 905 | 954 | 940 | 960 | 1.452 | 1.269 | 1.073 | 514 | **25.578** |
| InfoMoney | 2.109 | 2.237 | 1.776 | 1.389 | 1.393 | 1.171 | 975 | 776 | 702 | 865 | 1.134 | 1.569 | 2.640 | 2.332 | 2.275 | 1.692 | **25.035** |
| Money Times | | | | | | 25 | 401 | 747 | 1.399 | 1.984 | 2.400 | 3.135 | 2.484 | 1.515 | 1.464 | 1.322 | **16.876** |
| Valor | 183 | 508 | 538 | 401 | 375 | 447 | 321 | 344 | 738 | 934 | 1.250 | 1.526 | 2.337 | 2.920 | 2.244 | 1.370 | **16.436** |
| G1 | 2.423 | 2.280 | 1.929 | 594 | 597 | 602 | 427 | 307 | 430 | 441 | 501 | 453 | 620 | 403 | 464 | 382 | **12.853** |
| Poder360 | | | | | | 6 | 182 | 193 | 287 | 331 | 440 | 435 | 851 | 1.005 | 752 | 633 | **5.115** |
| O Globo | | | | | | | | | | | | 39 | 540 | 718 | 793 | 654 | **2.744** |
| Agência Brasil | | | | 208 | 218 | 250 | 176 | 227 | 171 | 188 | 208 | 163 | 134 | 121 | 137 | 101 | **2.302** |
| CartaCapital | | 57 | 58 | 29 | 12 | 7 | 9 | 6 | 20 | 42 | 78 | 113 | 354 | 306 | 248 | 178 | **1.517** |
| Bloomberg Línea | | | | | | | | | | | 200 | 390 | 347 | 278 | 176 | 119 | **1.510** |
| Folha | | | | | | | | 40 | 32 | 33 | 35 | 23 | 29 | 43 | 39 | 39 | **313** |
| **Total** | **7.304** | **7.934** | **7.475** | **5.567** | **4.484** | **4.107** | **3.831** | **3.762** | **4.684** | **5.772** | **7.186** | **8.806** | **11.788** | **10.910** | **9.665** | **7.004** | **110.279** |

Notícias no tema depois do dedup do corpus (inclui a quarentena de 10%). 2026 vai até 1º de setembro. Agência Brasil ainda em coleta.

**Figura 1:** Notícias por veículo e ano no corpus final. Barras: os cinco maiores veículos em cor e os demais em cinza; tabela: todos os veículos, com totais.

**Uso dos dados.** O texto das matérias é de terceiros e não é redistribuído. São públicos apenas agregados, contagens e identificadores opacos.

## 3 Instrumento

Cada notícia é lida, uma por chamada, por um LLM com prompt de sistema fixo (v1.1, *hash* `c4cd8123f2832031`), temperatura zero e saída JSON. Três dimensões, em escalas de 1 a 5 com âncoras:

D1 **probabilidade percebida de cumprimento da meta**. O modelo decide primeiro se há sinal sobre o cumprimento; sem sinal, não há nota. Com sinal: 1 = descumprimento certo, 3 = equilibrado, 5 = cumprimento certo.

D2 confiança na condução da política monetária (diagnóstica).

D3 autonomia percebida frente ao governo (diagnóstica).

O índice usa só a D1. O prompt manda avaliar a percepção que o texto transmite, separa pessimismo macroeconômico de descrédito na autoridade monetária, conta ironia e escolha de fontes céticas como sinal e pede que o modelo se comporte como na data de publicação. A v1.1 difere da v1.0 numa única regra: separa "sem sinal" de "equilibrado", que a v1.0 juntava na nota 3.

**Modelos.** Série principal: Sabiá (Maritaca AI, *sabiazinho-4*). Robustez: Gemini 3.1 Flash-Lite (Google) nas mesmas notícias. O Gemini foi pontuado pela API de lote, com a mesma requisição da chamada individual; num teste com 30 notícias com sinal, as notas de D1, D2 e D3 foram idênticas nas duas vias. Várias notícias por chamada foram testadas e rejeitadas: a nota de uma notícia passa a depender das outras do lote.

## 4 Do item ao índice

Para cada item $i$ com sinal na D1, $c_i = (d_{1,i} - 1)/4 \in [0, 1]$. Com o *cluster* de agência colapsado em uma observação $k$ por mês, o efeito de tipo de veículo é estimado em $c_{kt} = \alpha_t + \gamma_{v(k)} + e_{kt}$ e o índice mensal é a média dos itens ajustados,

$$\hat{C}_t^{LLM} = \frac{1}{N_t} \sum_{k \in S_t} \left( c_{kt} - \hat{\gamma}_{v(k)} \right), \tag{2}$$

com erro-padrão agrupado por dia. A regra registrada antes da validação reporta duas séries: a mensal e a janela móvel de três meses para trás, que soma itens de $t - 2$ a $t$. O índice diário serve ao estudo de eventos; D2 e D3 usam a média ponderada pelo desenho do pré-filtro.

## 5 Pré-filtro de sinal com auditoria aleatória

A maior parte das notícias não traz sinal sobre a meta. Um classificador local (BERTimbau, Souza, Nogueira e Lotufo, 2020) decide o que vai à API, e uma auditoria aleatória mede o que se perde.

1. **Rotulagem.** Uma amostra aleatória da produção é pontuada inteira pela API: 9.000 notícias do corpus original e 15% das notícias novas, sorteadas pelo *hash* do identificador (6.017).

2. **Filtro único.** O BERTimbau é treinado uma vez, com os rótulos do Sabiá das duas amostras (11.997 para treino, 2.999 para validação), e vale para o corpus inteiro. Metade da validação escolhe o limiar para sensibilidade de pelo menos 95%; a outra metade mede a sensibilidade.
3. **Roteamento.** Vai à API o que passa do limiar e, por sorteio, 10% das descartadas (auditoria). Notas já existentes são reaproveitadas.

O filtro tem AUC de 0,981 e sensibilidade de 95,3% na metade de teste (limite inferior de 92,2%, Clopper–Pearson unilateral a 95%), com 74% das notícias descartadas. Por veículo (Tabela 1), a sensibilidade fica entre 97% e 100%, exceto Exame (91%) e Valor (89%); com 35 e 54 positivos, os intervalos são largos. Valor fica abaixo do patamar de 90% registrado e entra nas limitações.

**Tabela 1:** Sensibilidade do filtro por veículo, na metade de teste.

| Veículo | Positivos | Sensibilidade | Limite inferior 95% |
|---|---|---|---|
| Valor | 54 | 0,889 | 0,79 |
| Exame | 35 | 0,914 | 0,79 |
| Money Times | 34 | 0,971 | 0,87 |
| G1 | 32 | 1,000 | 0,91 |
| InfoMoney | 30 | 1,000 | 0,90 |
| Poder360 | 11 | 1,000 | 0,76 |
| CartaCapital, Ag. Brasil, Línea, O Globo, Folha | 17 | 1,000 | — |

**Tabela 2:** Contagens do corpus à série (Sabiá).

| | |
|---|---|
| Corpus | 110.279 |
| Quarentena (fora da produção) | 11.033 |
| Produção | 99.246 |
| rotulagem (inteira à API) | 15.017 |
| enviadas pelo filtro | 22.438 |
| descartadas e auditadas (à API) | 6.179 |
| descartadas não enviadas (56,0% da produção) | 55.612 |
| Notas da API sem sinal na D1 | 29.733 |
| Notas da API com sinal na D1 | 13.901 |
| Taxa de sinal na auditoria | 0,73% |
| Sinal perdido estimado | $\approx$ 405 notícias (2,8% do sinal) |
| Erros da API | 0 |

Pelo critério do Gemini, a auditoria encontra mais sinal nas descartadas (2,2%), o que dá 6,3% de sinal perdido; com o filtro anterior eram 13%. Como robustez, o índice com pesos de Horvitz e Thompson (1952) na forma de Hájek (peso 10 para as auditadas) tem correlação de 0,996 com o índice simples.

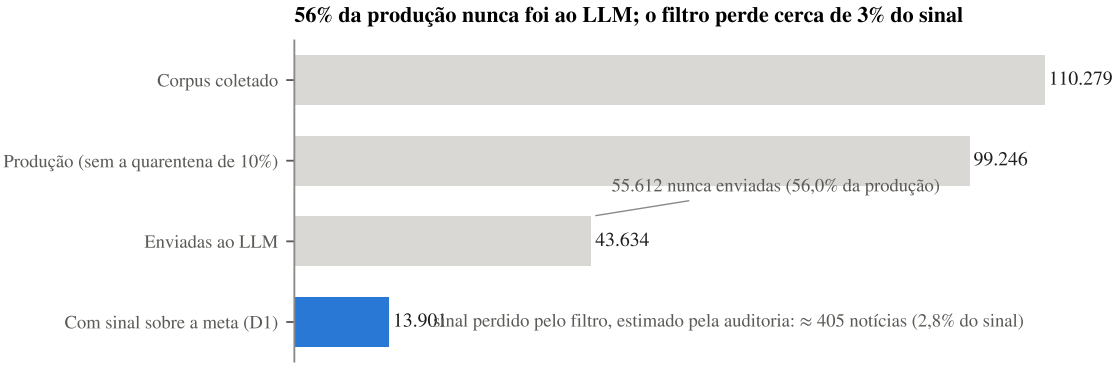



**Figura 2:** Do corpus às notícias com sinal sobre a meta.

# 6 Resultados: o índice

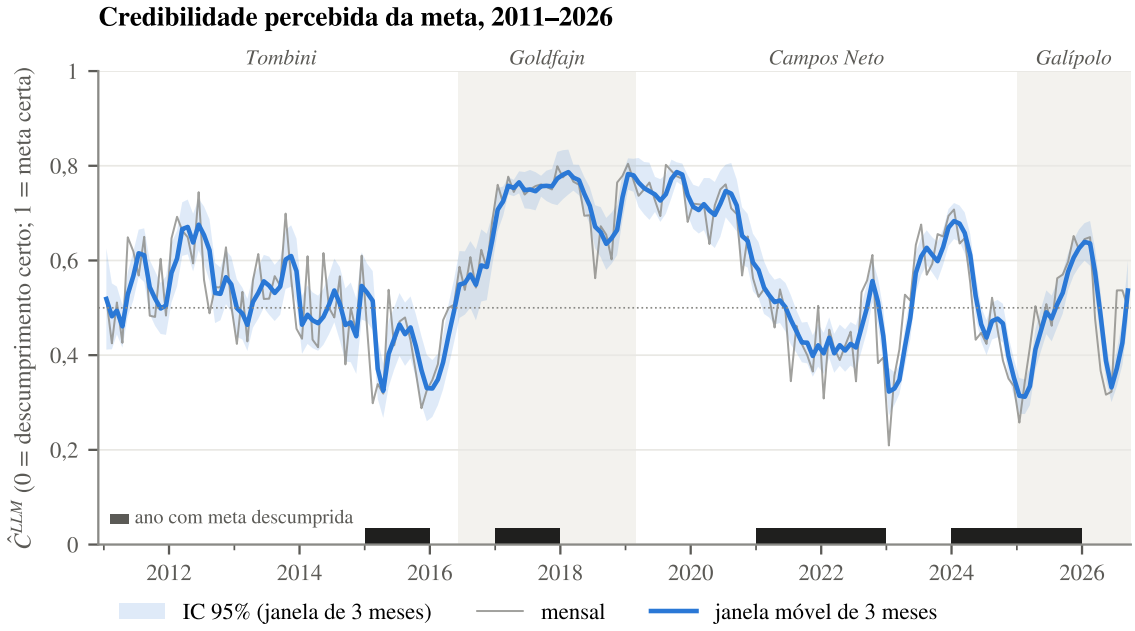
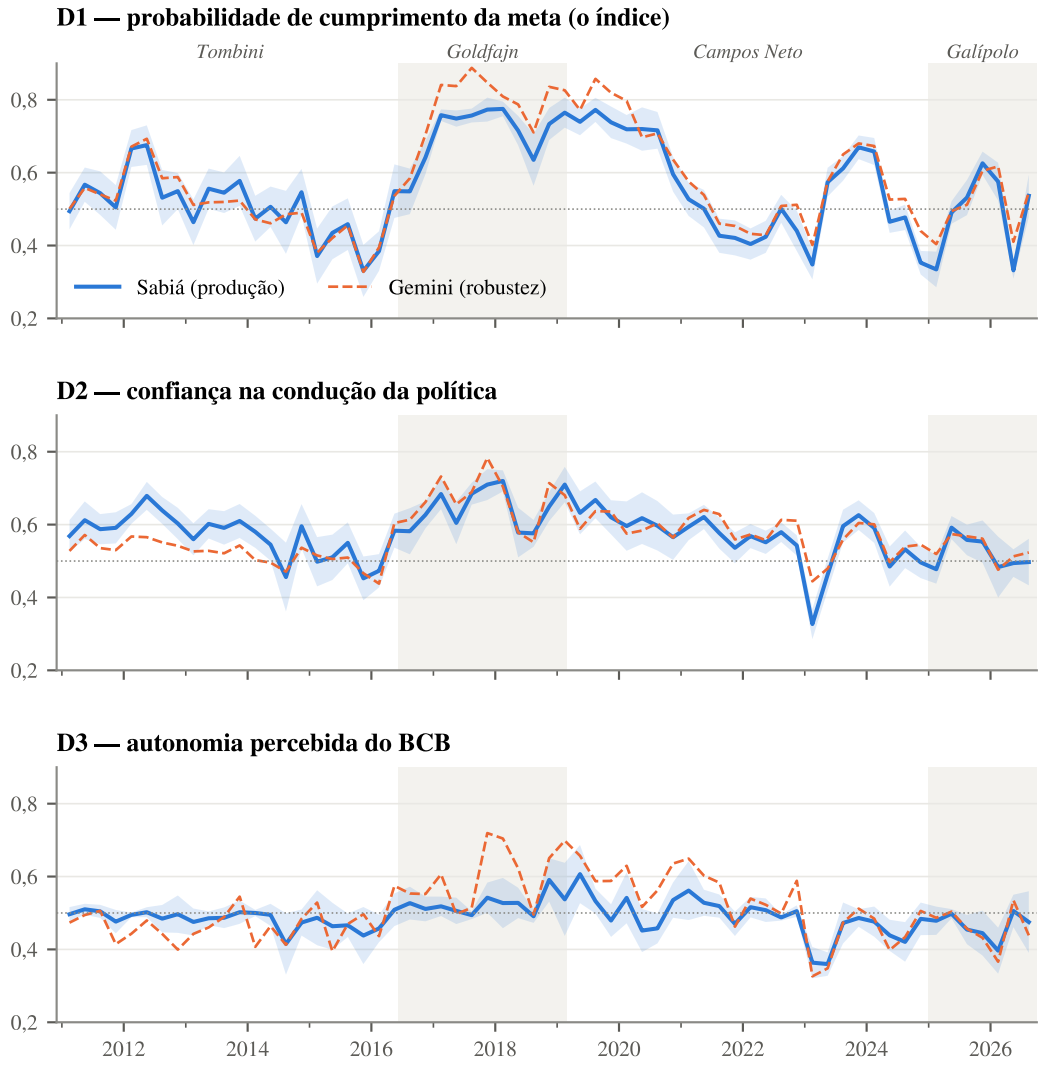



**Figura 3:** Índice mensal e janela móvel de três meses (Sabiá), com a meta e as gestões do BCB.

O índice mensal tem média 0,559 e desvio-padrão 0,139. O máximo é janeiro de 2019 (0,80) e o mínimo, janeiro de 2023 (0,21). Por gestão: Tombini 0,51, Goldfajn 0,71, Campos Neto 0,56 e Galípolo 0,49 (até agosto de 2026). A mediana de notícias com sinal por mês é 63 (8 meses com menos de 20); na janela de três meses, 185 (mínimo de 51). O erro-padrão mensal médio é 0,044.

A ampliação do corpus muda pouco a série e muito a sua precisão: contra o índice do corpus original, a correlação é 0,958 e a diferença média, −0,007, enquanto as notícias com sinal por mês praticamente dobram. Sabiá e Gemini têm correlação de 0,942 (mensal) e 0,962 (janela de três meses); o Gemini fica em média 0,03 acima.




Trimestral; faixa = IC 95% (Sabiá). D2 e D3 ponderadas pelo desenho do pré-filtro.

**Figura 4:** D1, D2 e D3 (Sabiá e Gemini). D2 e D3 são diagnósticas.

# 7 Robustez da construção

Todas as versões são reagregações das notas existentes, sem chamadas novas.

**Tabela 3:** Correlação com o índice principal (mensal; entre parênteses, janela de três meses).

| Versão | Correlação | Notícias com sinal/mês |
|---|---|---|
| Efeito fixo por veículo | 0,998 (0,998) | 64 |
| Só veículos presentes em toda a série | 0,983 (0,997) | 49 |
| Só os 5 veículos originais | 0,955 (0,985) | 30 |
| Só InfoMoney | 0,911 (0,957) | 12 |
| Só Valor | 0,803 (0,889) | 13 |
| Só a amostra aleatória (sem filtro) | 0,857 (0,954) | 10 |
| Sem Exame / sem G1 | 0,989 / 0,993 | 45 / 49 |
| Sem Agência Brasil, Línea, CartaCapital ou Folha | ≥ 0,999 | 60–63 |
| Outro modelo (Gemini) | 0,942 (0,962) | — |

Nenhuma fonte nova sozinha move o índice: retirar qualquer uma mantém correlação de pelo menos 0,989. A versão sem o filtro (só a amostra aleatória) acompanha a principal na janela de três meses (0,954); no mensal, a correlação menor reflete as 10 notícias com sinal por mês.

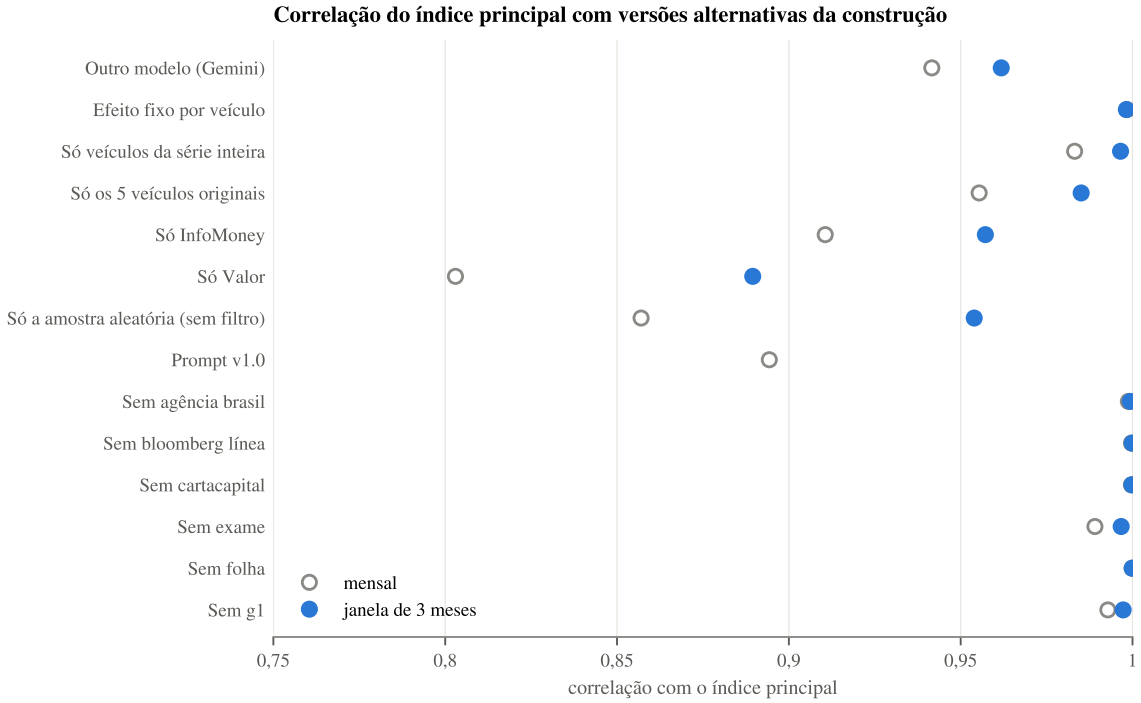



**Figura 5:** Correlação do índice principal com versões alternativas.

# 8 Vazamento temporal

Nenhum LLM de fronteira é temporalmente cego. O desenho limita o vazamento por construção (trecho curto, âncoras explícitas, restrição temporal no prompt), mede-o e o reporta.

## 8.1 Vazamento do pesquisador

O prompt é congelado e identificado por *hash*; 10% do corpus fica em quarentena; critérios e regras de agregação são registrados antes de rodar; revisões posteriores são declaradas. A revisão v1.0→v1.1,

a regra da janela de três meses e o desenho das fontes novas foram registrados antes dos resultados que dependiam deles.

## 8.2 Bateria de testes

**Tabela 4:** Bateria anti-vazamento (registrada antes de rodar).

| Teste | Resultado | Veredito |
|---|---|---|
| T0 (datar o texto, L1–L5) | o modelo data o texto mesmo mascarado (erro de 1,6 a 3,3 anos) | reprova |
| T2 (data omitida/trocada) | nota muda em 3–4% das notícias; $\rho$ com a surpresa futura $\leq 0{,}10$ ($p \geq 0{,}24$) | passa |
| T3 (anonimização L1–L4) | muda em 1–5%; L4 com $\rho = 0{,}20$ ($p = 0{,}02$) apoiado em 2 notícias | passa, frágil |
| T4 (resíduo V-max sobre V-min) | coeficiente 0,010 ($p = 0{,}34$), 176 meses, 12.014 notícias; $\rho$ por notícia 0,05 | passa |
| T5 (pares sintéticos) | diferença pareada 0,00 | passa |
| T6 (encoder local, pós-2019) | correlação BERTimbau × Sabiá 0,94 antes e depois de 2019 | sem sinal |

O T0 é condição suficiente, não necessária: o modelo sabe datar o texto, mas omitir, trocar ou mascarar a data e os identificadores quase não muda a nota, e o que muda não se correlaciona com o desfecho futuro (T2–T5).

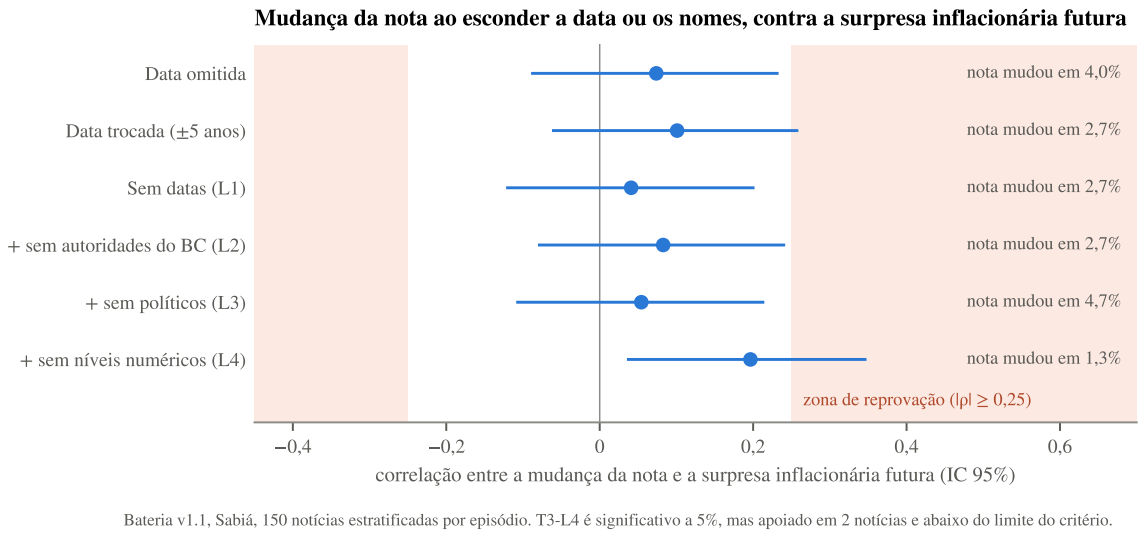



**Figura 6:** T2 e T3: correlação entre a mudança da nota, ao esconder a data ou os nomes, e a surpresa inflacionária futura (bateria v1.1, Sabiá).

## 8.3 Banda V-max/V-min

A V-min repontua as notícias no nível L5 (sem números, nomes, termos de época e veículo). Ela é reportada como *limite inferior* da informação do índice, não como veto: o L5 retira também os números de inflação, que são evidência legítima da D1. Pelo registro 4.2.20, a V-min cobre a amostra aleatória de 9 mil notícias e **todas as notícias com sinal no V-max** (21.576 notícias; 12.283 com sinal na V-min).

**Tabela 5:** Banda V-max/V-min (Sabiá, mensal).

| | |
|---|---|
| Correlação mensal V-max × V-min | 0,956 (189 meses) |
| Notícias com sinal por mês na V-min (mediana) | 53 |
| $\Delta_t = \hat{C}_t^{V\text{-}max} - \hat{C}_t^{V\text{-}min}$, média (desvio) | −0,013 (0,041) |
| Mesma nota D1 nas duas variantes | 84% das notícias |
| *Encompassing* da V-min sem rival | $b_1 = 0{,}33$ ($p = 0{,}003$) |

Com o texto mascarado, o índice quase não muda: correlação de 0,956 e diferença média de −0,013. Por ano, $\Delta_t$ fica entre −0,05 (2016 e 2025) e +0,04 (2020), sem tendência: positivo em 2017–2020 e negativo no resto. O sinal acompanha a era, o que é compatível com um prior de época, mas também com a perda dos números de inflação no L5, que puxa a nota para o meio da escala. O T4 separa as duas leituras: o resíduo da V-max dada a V-min não se correlaciona com a surpresa futura. A V-min também passa pela validação: sozinha, explica o latente do Kalman ($b_1 = 0{,}33$, $p = 0{,}003$) e sobrevive a 4 dos 9 rivais, contra 5 da V-max. Na amostra anterior de 9 mil notícias (cerca de 7 com sinal por mês), a correlação era de 0,80; a diferença vem do tamanho da amostra, não do índice.

# 9 Validação: validade de construto

Sem gabarito observável, o índice é defendido por uma bateria com critérios registrados antes de rodar (Baker, Bloom e Davis, 2016). Toda variável é orientada como "maior = mais credibilidade"; erros de Newey e West (1987) com $h + \lfloor 4(n/100)^{2/9} \rfloor$ defasagens. Série principal: Sabiá mensal. As séries de fornecedor (EMBI+, CDS) entram nas regressões, mas não são publicadas.

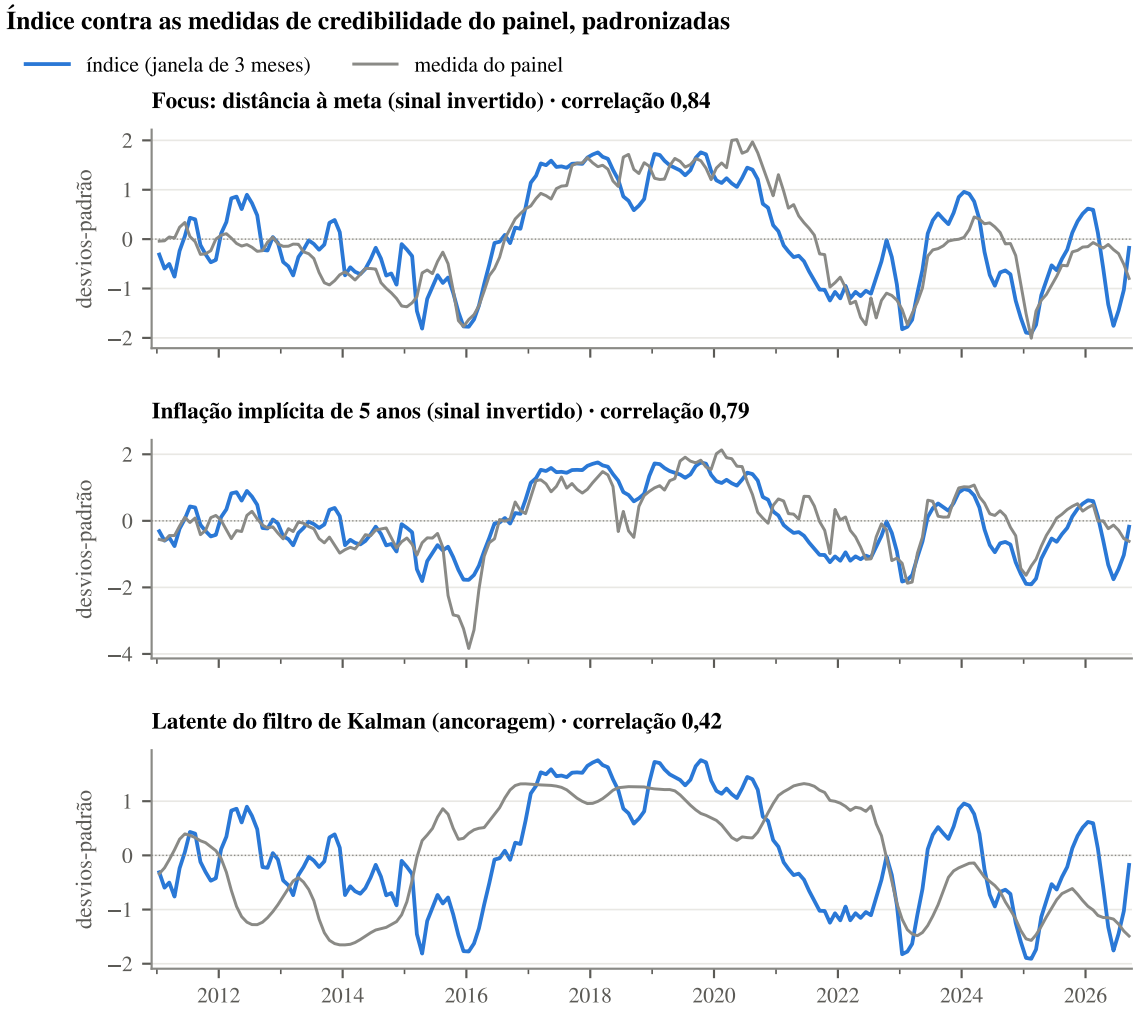
**Tabela 6:** Vereditos da bateria (Sabiá mensal).

| Teste | Critério registrado | Resultado |
|---|---|---|
| 7.1 Convergente | correlação positiva, $p < 5\%$, com o *breakeven* e com uma medida do Focus | **aprovado** |
| 7.2 Discriminante | $R^2$ da inflação $< 0{,}8$ e $c > 0$, $p < 5\%$, para *breakeven* ou EMBI+ | **aprovado** |
| 7.3 Preditiva | $b > 0$, $p < 5\%$, para a distância do Focus à meta em $h = 6$ | **aprovado** |
| 7.4 *Encompassing* | — (reportado) | sobrevive a 5 de 9 rivais |

## 9.1 Convergente

**Tabela 7:** Correlação do índice com as medidas do painel (valor-p HAC).

| Medida | Mensal | Janela de 3 meses |
|---|---|---|
| Distância do Focus à meta (sinal invertido) | 0,75 (0,00) | 0,84 (0,00) |
| Inflação implícita de 5 anos (sinal invertido) | 0,74 (0,00) | 0,79 (0,00) |
| de Mendonça (2007) | 0,68 (0,00) | 0,76 (0,00) |
| Dispersão do Focus (sinal invertido) | 0,57 (0,00) | 0,63 (0,00) |
| de Mendonça e Souza (2009) | 0,44 (0,00) | 0,51 (0,00) |
| Latente do Kalman | 0,38 (0,00) | 0,42 (0,00) |
| CDS (sinal invertido; desde 2019) | 0,22 (0,21) | 0,23 (0,23) |
| Inclinação da curva | 0,18 (0,10) | 0,27 (0,01) |
| EMBI+ (sinal invertido) | 0,13 (0,37) | 0,13 (0,41) |




Séries padronizadas. Em 2021, a meta estourou (o índice cai) com expectativas ancoradas (o latente sobe).

**Figura 7:** Índice contra o Focus, a inflação implícita e o latente do Kalman.

## 9.2 Discriminante

A inflação corrente (desvio da meta, variação em 12 meses e estouro do teto) explica 42% da variância do índice mensal; o restante vem do texto (Figura 8). Controlando por inflação, o índice padronizado explica a inflação implícita ($c = 0{,}48$, $p < 0{,}001$) e a distância do Focus à meta ($c = 0{,}45$, $p < 0{,}001$). Com o EMBI+ o coeficiente é *negativo* ($c = -16$, $p = 0{,}02$): dada a inflação, meses de maior credibilidade percebida coincidem com risco-país maior. O EMBI+ carrega risco fiscal e global que a D1 não mede; o resultado vai para a discussão, não para o critério, que já é cumprido pelo *breakeven*.

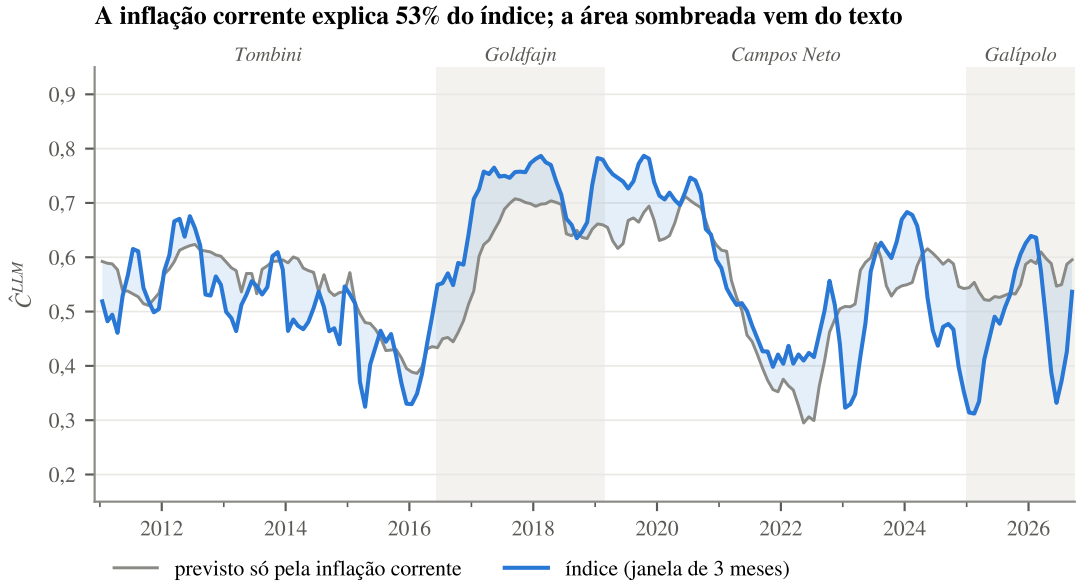


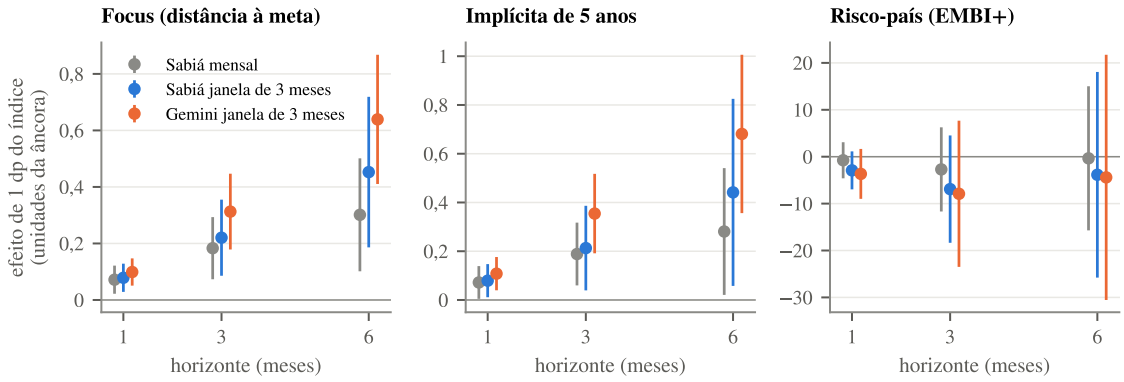

**Figura 8:** Parte do índice explicada pela inflação corrente e parte que vem do texto.

## 9.3 Preditiva

$$y_{t+h} - y_t = a + b\, z(\hat{C}_t^{LLM}) + c\, y_t + d\, \Delta y_t + e\, g_t + \varepsilon_{t+h}. \tag{3}$$

Primário: distância do Focus à meta em $h = 6$, $b = 0{,}30$ ($p = 0{,}003$; Holm 0,009). O índice também antecipa o Focus em 1 e 3 meses. A inflação implícita tem $b = 0{,}28$ ($p = 0{,}03$) em $h = 6$, que não sobrevive à correção de Holm (0,07) no mensal e sobrevive na janela de três meses (0,05) e no Gemini (0,001). O EMBI+ não é antecipado em nenhum horizonte.

**Poder preditivo do índice a 1, 3 e 6 meses, além da própria história de cada alvo**




Controla pelo nível e pela variação da âncora e pelo desvio da inflação à meta; IC 95% Newey–West. Teste primário: Focus, h = 6.

**Figura 9:** Coeficiente do índice na previsão de cada alvo a 1, 3 e 6 meses.

### 9.4 *Encompassing* contra o latente do Kalman

O latente $\hat{C}_t^{KF}$ vem só do Focus, da meta e do IPCA defasado, num modelo de parâmetro variável no tempo com elo logístico, estimado por filtro de Kalman estendido. Sozinho, o índice explica o latente ($b_1 = 0{,}38$, $p = 0{,}001$, $R^2 = 0{,}15$) e continua significativo com 5 dos 9 rivais (de Mendonça e Souza, dispersão do Focus, CDS, EMBI+ e inclinação). Perde significância com de Mendonça (2007), com a inflação implícita e com todos os rivais juntos. Os dois objetos não coincidem por construção: $\hat{C}_t^{KF}$ mede quanto o Focus fica perto da meta apesar da inflação passada, e a D1, se a meta será cumprida. Em 2021 a meta estourou, o índice caiu e o latente subiu.

## 10 Aplicação: estudo de eventos

**Reuniões do Copom.** $\Delta_m = \bar{c}_{[D+1,D+7]} - \bar{c}_{[D-7,D-1]}$ regredido na surpresa do swap DI×Pré de 3 meses (B3) de $D-1$ a $D+1$, erro HC1. O teste primário (7 dias) não é significativo: +0,009 por 10 pb ($p = 0{,}42$, 115 reuniões). Na janela de 14 dias, secundária, o efeito é +0,019 por 10 pb ($p = 0{,}007$): surpresas de aperto elevam a credibilidade percebida nas duas semanas seguintes. O tamanho da surpresa, sem sinal, não tem efeito.

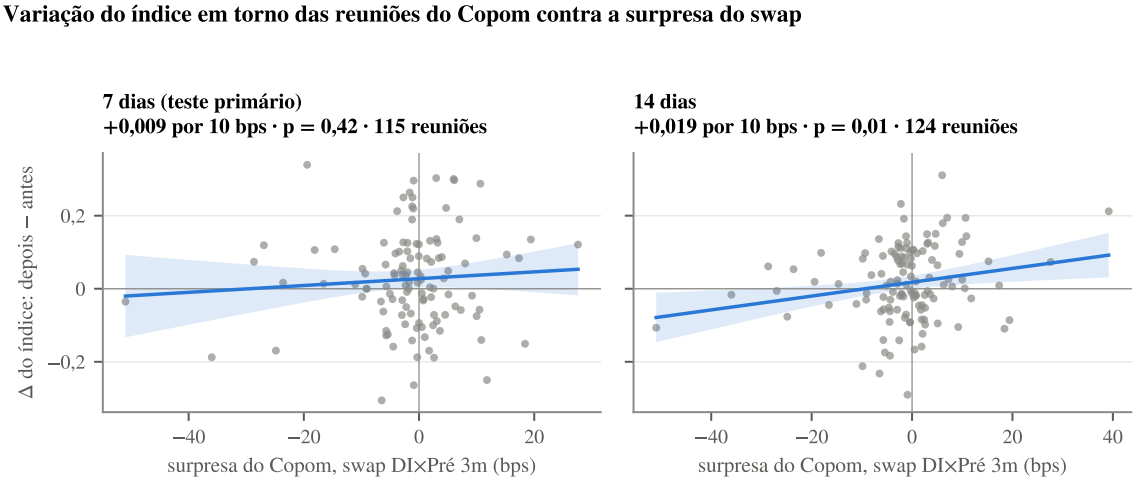



**Figura 10:** Variação do índice em torno das reuniões do Copom contra a surpresa.

**Eventos institucionais (exploratório).** Variação de D1, D2 e D3 em ±30 dias, contra a distribuição placebo de todas as datas. Nenhum evento sai da faixa de 5%. Os maiores, na D1: anúncio da diretoria de Goldfajn e da proposta de autonomia técnica em maio de 2016 (+0,13; 16% das datas placebo têm variação maior), críticas presidenciais à autonomia em janeiro de 2023 (+0,15; 10%) e a decisão dividida do Copom em maio de 2024 (−0,13; 16%). A alta de janeiro de 2023 parte do mínimo da série, em meio às notícias de estouro da meta de 2022.

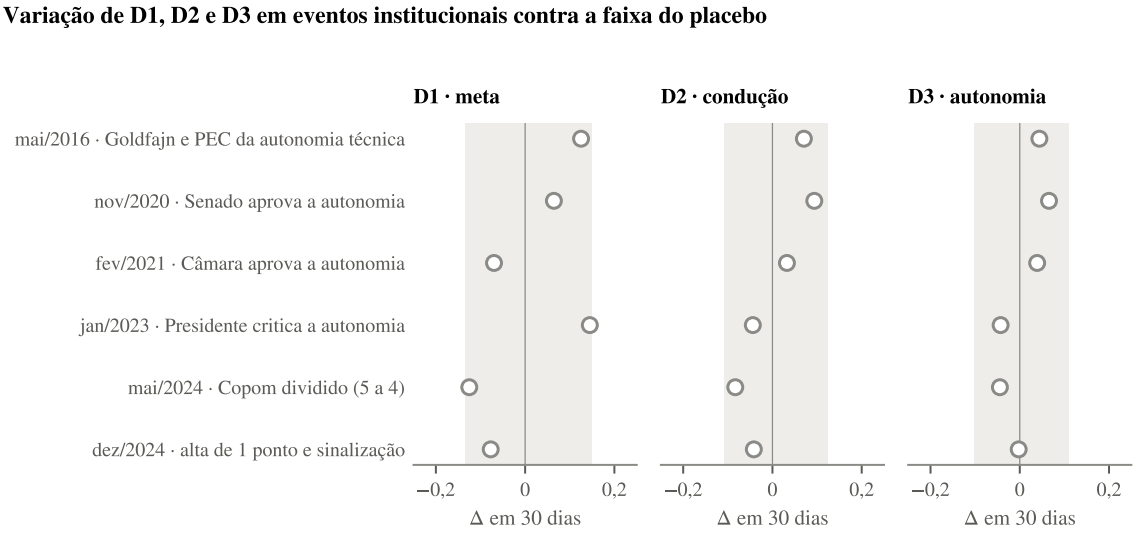



**Figura 11:** Variação de D1, D2 e D3 nos eventos institucionais e faixa placebo.

# 11 Limitações

1. **Composição do corpus.** O G1 concentra-se em 2011–2013 (cerca de 3 mil notícias por ano, contra 300–600 depois); a Agência Brasil começa em 2014, a Bloomberg Línea em 2021 e a Folha em 2018. O efeito fixo por veículo e as versões "sem a fonte" mostram efeito pequeno no índice.

2. **Filtro.** Sensibilidade de 89% no Valor e 91% na Exame, com intervalos largos; o sinal perdido é estimado pela auditoria e corrigido no IPW, mas não na série principal de D1.
3. **Cobertura das fontes por endereço.** Línea e Agência Brasil usam pré-filtro pelas palavras do endereço; matérias cujo endereço não traz os termos escapam.
4. **Vazamento.** O modelo data o texto (T0). A evidência de que a nota não usa o futuro vem de T2–T5 e da banda V-max/V-min; a V-min cobre só as notícias com sinal no V-max e a amostra aleatória, de modo que o efeito do vazamento sobre a *taxa* de sinal é medido só na amostra de 9 mil (14,7% para 15,4%).
5. **Âncoras.** A inflação implícita contém prêmios de risco e de liquidez; o EMBI+ e o CDS carregam risco fiscal e global.
6. **Quarentena congelada tarde.** O manifesto foi gerado depois de a série ter sido inspecionada; as séries mudaram pouco (correlação 0,997).

## 12 Custo e reprodução

As chamadas desta rodada (fontes novas, filtro único, V-min, Sabiá individual e Gemini em lote) custaram cerca de R$ 64, estimados pelas chamadas registradas (36.395 no Sabiá e 23.818 no Gemini em lote), dentro da verba de R$ 150. O código e as séries estão no repositório; a sequência é `coleta/` → `llm/corpus/from_coleta.py` → `llm/producao_v11.py` (rotulagem, filtro, roteamento, pontuação, V-min, consolidação) → `python -m validacao.artigo`.

## Referências


BAKER, S. R.; BLOOM, N.; DAVIS, S. J. Measuring economic policy uncertainty. *The Quarterly Journal of Economics*, v. 131, n. 4, p. 1593–1636, 2016.

BOMFIM, A. N.; RUDEBUSCH, G. D. Opportunistic and deliberate disinflation under imperfect credibility. *Journal of Money, Credit and Banking*, v. 32, n. 4, p. 707–721, 2000.

DE MENDONÇA, H. F. Towards credibility from inflation targeting: the Brazilian experience. *Applied Economics*, v. 39, n. 20, p. 2599–2615, 2007.

DE MENDONÇA, H. F.; GUIMARÃES E SOUZA, G. J. Inflation targeting credibility and reputation: the consequences for the interest rate. *Economic Modelling*, v. 26, n. 6, p. 1228–1238, 2009.

HOLM, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, v. 6, n. 2, p. 65–70, 1979.

HORVITZ, D. G.; THOMPSON, D. J. A generalization of sampling without replacement from a finite universe. *Journal of the American Statistical Association*, v. 47, n. 260, p. 663–685, 1952.

KALMAN, R. E. A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, v. 82, n. 1, p. 35–45, 1960.

KUTTNER, K. N. Monetary policy surprises and interest rates: evidence from the Fed funds futures market. *Journal of Monetary Economics*, v. 47, n. 3, p. 523–544, 2001.

NEWEY, W. K.; WEST, K. D. A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, v. 55, n. 3, p. 703–708, 1987.

SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. BERTimbau: pretrained BERT models for Brazilian Portuguese. In: *Brazilian Conference on Intelligent Systems (BRACIS)*. Cham: Springer, 2020. p. 403–417.